

Anwendungen von (orthogonaler) Projektionen in Statistik

Approximation in Subspace

aus geometrischer Sicht

I. Mittelwert-Berechnung: Erst gesagt kommen orthogonale Projektionen vor allem bei linearen Schätzern vor. Erwartungswerte sind meistens

$$\text{Bsp. 2D-Vektor mit zwei Werten } \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 3 \\ 1 \end{pmatrix}, \quad \bar{\mathbf{x}} = \text{proj}_{\mathbb{W}}(\mathbf{x}) = \frac{\langle \mathbf{x}, \begin{pmatrix} 1 \\ 1 \end{pmatrix} \rangle}{\langle \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \end{pmatrix} \rangle} \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \frac{3+1+1+1}{1+1+1+1} \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 2 \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix} \stackrel{\text{arithm. Rechnung}}{=} \text{ für } x_{\text{Mz.}} \frac{1}{2}(3+1)=2$$

\mathbb{W} ist quasi bester linearer Schätzer für jede Komponente von \mathbf{x} . Durch Projektion auf Winkelhalb. $\mathbb{W} = \text{Span}\left\{\begin{pmatrix} 1 \\ 1 \end{pmatrix}\right\}$ wird jeder x -Komponente selber ein neuer Wert (\bar{w}) zugewiesen.

$\text{Span}\left\{\begin{pmatrix} 1 \\ 1 \end{pmatrix}\right\}$ ist allgemein Menge aller konstanten Vektoren in \mathbb{R}^n mit identisch Einträgen in allen Dimensionen.

Mittelwert von $\mathbf{x} \in \mathbb{R}^n$ ist Projektion auf diesen WVR $\hat{\mathbf{x}}$ beste konstante Approximation des Vektors \mathbf{x}

Statistisch als Optimierungsproblem: $\bar{\mathbf{x}} = \underset{\mathbf{x} \in \mathbb{R}^n}{\text{argmin}} \sum_{i=1}^n (\mathbf{x}_i - \mathbf{x})^2$ eng verknüpft mit niedrigstem Abstand: $\bar{\mathbf{x}} = \text{proj}_{\mathbb{W}}(\mathbf{x}) = \underset{\mathbf{w} \in \mathbb{W}}{\text{argmin}} \|\mathbf{x} - \mathbf{w}\|$

III. Kleinstes Quadrat-Methode (KQ, OLS "Ordinary Least Squares")

Problem: Daten $(\mathbf{y}_1, \mathbf{x}_1), \dots, (\mathbf{y}_n, \mathbf{x}_n) \in \mathbb{R}^{p+1}$, also $p+1$ endständige Variablen bzw. \mathbf{p} + Intercept

Daten folgen Modell mit unbekannten Parametern β , also $y_i = \mathbf{x}_i^T \beta + \varepsilon_i \quad i = 1, \dots, n$

Zufallsfehler, sonst unsinnisch

$\beta = \mathbf{x}^{-1} \mathbf{y}$ weil \mathbf{x} nicht invertierbar

Jas LGS $\mathbf{X}\beta = \mathbf{y}$ soll uns den passenden Parametervektor β liefern, aber es gibt i.d.R. keine Lösung. Minimiere deutlich mehr Beobachtungen als Parameter (Zellen \Rightarrow Spalten von \mathbf{X})

$$\begin{aligned} \mathbf{X} &= \begin{pmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_n^T \end{pmatrix} \text{ Zeile Zelle ist ein Beobachtungssatz} \\ \text{Zeilen } \rho &= \begin{pmatrix} 1 & \mathbf{x}_{1,1} & \dots & \mathbf{x}_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & \mathbf{x}_{n,1} & \dots & \mathbf{x}_{n,p} \end{pmatrix} = \begin{pmatrix} \mathbf{y}_1 \\ \vdots \\ \mathbf{y}_n \end{pmatrix} \\ \beta &\in \mathbb{R}^{p+1} \end{aligned}$$

Technik: Minimieren nur den Abstand zwischen $\mathbf{X}\beta$ und \mathbf{y} möglichst klein machen, um beste Approximation von $\mathbf{X}\beta$ an die Beobachtungen zu finden

Äquivalent ist Minimierung von $\|\mathbf{X}\beta - \mathbf{y}\|^2 = \sum_{i=1}^n \varepsilon_i^2 = \varepsilon_1^2 + \varepsilon_2^2 + \dots + \varepsilon_n^2$ (Z_i: $y_i - \hat{y}_i$) \Leftrightarrow Norm breit. Bedeutung in 1D, weil $Z_i(y_i - \hat{y}_i)$ kann=0 sein, müssen Abweichungen auch oben unten, die sich in Summe concidieren

Lösung: Suchen $\hat{\beta} = \mathbf{X}\hat{\beta} \in \text{col}(\mathbf{X})$ mit minimalem Abstand zu \mathbf{y} . Dies ist die Projektion von \mathbf{y} auf $\text{col}(\mathbf{X})$. Fazit: Haben dann $\hat{\beta}$ s.d. $\mathbf{X}\hat{\beta} = \hat{\mathbf{y}}$

i) 1. Projiziere \mathbf{y} orthogonal auf $\text{col}(\mathbf{X})$ 2. Löse das LGS $\mathbf{X}\hat{\beta} = \hat{\mathbf{y}}$ nach $\hat{\beta}$ Achtung! \mathbf{y} ist eindimensional, $\hat{\beta}$ überleiderlich zugeordnet \mathbf{X} muss orthonormierte Spalten haben. Falls nicht \rightarrow Gram-Schmidt vorher (\mathbf{X} muss überlinear unabh. Spalten haben!).

ii) Projektion durchzuführen ist sogar optional, denn Lsg menge von KQ Problem \cong Lösung(en) der Normalgleichungen $(\mathbf{X}^T \mathbf{X})\hat{\beta} = \mathbf{X}^T \mathbf{y}$

Spalten von \mathbf{X} müssen hierfür nur linear unabh. sein, denn genau dann ist $\mathbf{X}^T \mathbf{X}$ invertierbar

$\mathbf{X}^T \mathbf{X}$ Inv. bar $\Rightarrow \mathbf{X}^T \mathbf{X} \vec{v} = 0$ hat nur triviale Lsg $\vec{v} = \vec{0}$, $\mathbf{X}^T \mathbf{X} v = 0 \Leftrightarrow (\mathbf{X}^T \mathbf{X})^T \mathbf{X} v = \mathbf{X}^T \mathbf{X} \vec{0} = 0 \Leftrightarrow \|\mathbf{X}^T \mathbf{X} v\|^2 = 0 \Rightarrow \mathbf{X}^T \mathbf{X} v = 0$

$\rightarrow \mathbf{X}$ Inv. bar, voller Rang, $\mathbf{X}\mathbf{v} = 0$ hat nur triviale Lsg.

Falsch: Spalten linear abh. (oder bei Multikollinearität anstrengend ab, was zumunstreich instabil er inverse($\mathbf{X}^T \mathbf{X}^{-1}$) führt), so braucht es andere Ansätze (siehe mit ihren Problemen).

Wie etwa SGD-basierte Pseudo-Inverse, Regularisierung via Ridge Regression (!), PCA zur Datenevaluation auf orthogonale Dimensionen, Minimalk-Entfernung etc.

iii) Weitere äquivalente Lösungen, die über steile MLE-verzerrte Schätzer für Fehlermautrie liefern oder aus anderen Gründe setzen zum Einsatz kommen

Bewertung der Genauigkeit von Vorhersage-/Erklärmödellen, insbes. bei Modellierung linearer Zusammenhänge. Maum geht es eigentlich? Mauteaufheit und Hypothesenprüfung mit "Mean Square Error" (MSE) bzw. dessen "Wurzel-Root" (RMSE) beurteilt

$$\begin{aligned} \text{MSE} &= \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ &= \frac{1}{n} \|\mathbf{y} - \hat{\mathbf{y}}\|^2 \\ &= \frac{1}{n} \langle \mathbf{y} - \hat{\mathbf{y}}, \mathbf{y} - \hat{\mathbf{y}} \rangle = \frac{1}{n} ((y_1 - \hat{y}_1)^2 + \dots + (y_n - \hat{y}_n)^2) \end{aligned}$$