

Übung 09

$A \in \mathbb{R}^{n \times n}$

Fragestellungen i) A sei symmetrische Matrix mit nur einem einzigen Eigenwert $\lambda \Rightarrow$ das Polynom $\det(A - \lambda I)$ hat eine Lsg. λ^*

Beweise, dass dieses A eine Skalarmatrix ist, also Diagonalmatrix mit einem ident. Wert auf Diagonale

also $A - \lambda I = \begin{pmatrix} a_{11}-\lambda & & 0 \\ & \ddots & \\ 0 & & a_{nn}-\lambda \end{pmatrix}$ alle Diagonaleinträge gleich
 und $\det(A - \lambda I) = (\lambda^* - \lambda)^n = 0 \Rightarrow \lambda^* = \lambda$ Vermeidung: $\lambda^* = \lambda$ sonst nur Nullvektor

Sei $A^{n \times n}$ symmetrisch, also: $A = P D P^T$ mit $P^{n \times n}$ Orthogonalmatrix, D Diagonalmatrix
 $\Rightarrow A = P(\lambda^* I) P^T = \lambda^* P I P^T = \lambda^* P P^T = \lambda^* I$ also: $A = \lambda^* I_n$

P Orthogonalmatrix

Beispiele: Nullmatrix mit $\lambda^* = 0$, Identitätsmatrix I mit $\lambda^* = 1$, Matrix $2I$ mit $\lambda^* = 2$ etc.

ii) Definiert $g: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}, (x, y) \mapsto \langle x - y \rangle$ ein Skalarprodukt auf \mathbb{R}^n ? Nein

g nicht positiv definit: für alle $x \in \mathbb{R}^n$ gilt $g(x, x) = \|x - x\|^2 = 0$, aber für Skalarprodukt müsste aus $g(x, x) = 0$ immer $x = 0$ folgen

Aufgabe 1. Sei A symmetrische $n \times n$ Matrix

A sei positiv definit, also $x^T A x \geq 0$ für alle $x \in \mathbb{R}^n$ und $x^T A x = 0$ g.d.w. $x = 0$

a) Zeige, dass $g: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}, (x, y) \mapsto x^T A y$ ein Skalarprodukt auf \mathbb{R}^n definiert

• g positiv definit, weil A positiv definit $g(x, x) = x^T A x \geq 0$ und $x^T A x = 0 \Leftrightarrow x = 0$ ✓

• g symmetrisch, da A symmetrisch $[A = A^T] \quad g(x, y) = x^T A y = (x^T A y)^T = y^T A^T x = y^T A x = g(y, x)$ ✓

• g bilinear $\text{Abb. } h: \mathbb{R}^n \rightarrow \mathbb{R}, x \mapsto x^T A y$ ist linear, denn für alle $x \in \mathbb{R}^n$ gilt: $x^T A y = (x^T A y)^T = y^T A^T x = y^T A x = g(y, x)$ ✓

altern. $g(\lambda x, y) = (\lambda x)^T A y = \lambda x^T A y = \lambda g(x, y)$

$g(x, y, z) = (x + y)^T A z = (x^T + y^T) A z = x^T A z + y^T A z = g(x, z) + g(y, z)$ ✓

b) Folgere nun, dass das Standardskalarprodukt $\langle x, y \rangle = \sum_{i=1}^n x_i y_i$ und das gewichtete eukl. Skal. prod. $\langle x, y \rangle_w = \sum_{i=1}^n w_i (x_i y_i)$ mit $w_i > 0$ beides Skalarprodukte definieren. \Rightarrow Beides sind Spezialfälle von $x^T A y$

Stand. Skalarprod. $\langle x, y \rangle = x^T I y$ also $A = I$ I erfüllt positive Definitheit denn $x^T I x = \sum_{i=1}^n x_i^2 \geq 0$ und $= 0$ g.d.w. $x = 0$

I offensichtlich symmetrisch Matrix

Gewicht. $\langle x, y \rangle_w = x^T \text{diag}(w) y$ erfüllt man mit $A = \text{diag}(w)$ ergo Diagonalmatrix mit Diagonal-Einträgen w_1, \dots, w_n
 Matrix $\text{diag}(w)$ ist als Diagonalmatrix symmetrisch, pos.-definit erfüllt weil $x^T \text{diag}(w) x = \sum_{i=1}^n w_i x_i^2 \geq 0$ da $w_i > 0$ und $= 0$ nur wenn $x = 0$

Man kann "zeigen": Für jedes Skalarprodukt g auf \mathbb{R}^n existiert genau eine pos. definite u. symmetrische Matrix A , sodass $g(x, y) = x^T A y$

Sei $g(x, y) = \langle x, y \rangle$ beliebiges Skalarprod. auf \mathbb{R}^n

Es ist $\langle x, y \rangle = \langle \sum_{i=1}^n x_i e_i, \sum_{j=1}^n y_j e_j \rangle = \sum_{i,j=1}^n x_i y_j \langle e_i, e_j \rangle = x^T A y$ A muss pos. definit und symmetrisch sein, weil g dies ist
 bilinear A eindeutig, weil ...

Aufgabe 2. Orthogonale Spektralzerlegung

Symmetrische Matrix $A = \begin{pmatrix} 1 & 2 \\ 2 & -2 \end{pmatrix}$

EV/Eigenräume: $(A - \lambda_1 I) v_1 = 0 \Rightarrow \begin{pmatrix} 1-1 & 2 \\ 2 & -2-1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 & 2 \\ 2 & -3 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$
 $(A - \lambda_1 I) v_1 = 0 \Rightarrow \begin{pmatrix} 0 & 2 \\ 2 & -3 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow \begin{pmatrix} 2y \\ 2x - 3y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow \begin{pmatrix} y \\ x - 1.5y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow \begin{pmatrix} y \\ x \end{pmatrix} = \begin{pmatrix} 0 \\ 1.5y \end{pmatrix}$
 $E_1 = \text{span}\{ \begin{pmatrix} 0 \\ 1 \end{pmatrix} \}, v_1 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ $E_1 \perp E_2, \langle v_1, v_2 \rangle = 0$

Eigenräume sind orthogonal, also $v_1 \perp v_2$
 \Rightarrow Wir können direkt eine Gram-Schmidt-Verfahren weiter machen
 Müssen jedoch v_1, v_2 normieren, damit geeignet für Orthogonalmatrix-Spalten $v_1' = \frac{v_1}{\|v_1\|} = \frac{1}{\sqrt{1}} \cdot \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ \Rightarrow Matrix P bilden

Orthogonalmatrix P mit normierten Orth. Eigenvektoren $P = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & 2 \\ -2 & 1 \end{pmatrix}$, Diagonalmatrix $D = \text{diag}(-3, 2) = \begin{pmatrix} -3 & 0 \\ 0 & 2 \end{pmatrix}$

Also orthogonale Diagonalisierung: $A = P D P^T = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & 2 \\ -2 & 1 \end{pmatrix} \begin{pmatrix} -3 & 0 \\ 0 & 2 \end{pmatrix} \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & -2 \\ 2 & 1 \end{pmatrix}$

Spektralzerlegung als Summe von Projektionen: $A = \sum_{i=1}^n \lambda_i P_i$ $P_i = P \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} P^T$
 $A = -3 \begin{pmatrix} 1 & 2 \\ -2 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \frac{1}{5} + 2 \begin{pmatrix} 1 & 2 \\ -2 & 1 \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \frac{1}{5} = \begin{pmatrix} -3 & -6 \\ 6 & -3 \end{pmatrix} \frac{1}{5} + \begin{pmatrix} 2 & 4 \\ -4 & 2 \end{pmatrix} \frac{1}{5} = \begin{pmatrix} -1 & -2 \\ 2 & -1 \end{pmatrix}$

Wirkung auf Vektor $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$ $Ax = \begin{pmatrix} -1 & -2 \\ 2 & -1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -3 \\ 1 \end{pmatrix}$

Identität: $Ax = -3 \begin{pmatrix} 1 & 2 \\ -2 & 1 \end{pmatrix} \frac{1}{5} \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \frac{1}{5} + 2 \begin{pmatrix} 1 & 2 \\ -2 & 1 \end{pmatrix} \frac{1}{5} \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \frac{1}{5}$



Eingangsungen zu quadratischer Form und Definitheit symmetrischer Matrizen $A \in \mathbb{R}^{n \times n}$ "z.B. Gegenbsp. $B = \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix}$ $B^{-1} = B$ **B negativ definit**

algebrae schon weil Invertierbares A folgen nicht symmetr. sein muss und Definitheit nur für symmetr. Matrizen existiert (Klammer!)

i.v. Wenn A positiv definit $\Rightarrow A$ invertierbar, dann pos. definit bedeutet 0 ist kein Eigenwert von $A \Rightarrow A$ invertierbar gem. Figur. Theorem.

A pos. long. semidefinit $\Rightarrow A$ nicht invertierbar, weil mindestens ein EW = 0

Wenn A indefinit \Rightarrow ohne weitere Infos kann man daraus nichts über Invertierbarkeit schlussfolgern

Bsp. $A_1 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & -1 \end{pmatrix}$ Diagonalmatrix mit EW $\lambda_1=1, \lambda_2=0, \lambda_3=-1$ A_1 nicht invertierbar: Nullspalte \Rightarrow Spalten linear abh., $\det(A_1)=0$ **A hat keinen vollen Rang, nur Rang 2**

$A_2 = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$ Diagonalmatrix mit EW $\lambda_1=1, \lambda_2=-1$ A_2 invertierbar: $A_2^{-1} = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} = A_2$ selbst $A^{-1}=A$ (giltung 0+1) **Bsp. für selbstinverte Matrix**

ii) Wenn $A^{n \times n}$ invertierbar, ist $A^T A$ dann positiv definit? Zumindest ist $A^T A$ sicher symmetrisch

Ja. Es ist zu zeigen, dass $X^T (A^T A) X > 0$ für alle $\vec{0} \neq X \in \mathbb{R}^n$

Es ist: $X^T A^T A X = (A X)^T A X = \|A X\|^2$ **quadr. Form von $A^T A$** $\hat{=}$ **Normquadrat** von $A X$ $\|A X\|^2 = (\overbrace{\|A X\|}^2) = \langle A X, A X \rangle$

Wenn A invertierbar ist $A X \neq \vec{0} \forall X \neq \vec{0}$ weil $\ker(A) = \{0\} \Rightarrow \|A X\|^2 > 0 \forall X \neq \vec{0}$

ergo $X^T (A^T A) X = \|A X\|^2 > 0 \forall X \neq \vec{0} \Rightarrow A^T A$ positiv definit \square

Aufgabe 3. Quadratische Form ablesen / bestimmen mit expliziter Rechnung

$$v = \begin{pmatrix} 2 \\ 3 \\ 1 \end{pmatrix}$$

a) $A \in \mathbb{R}^{2 \times 2}$, $Q_A(x) = 2x^2 + 6xy + 5y^2$ A so bestimmen, dass $Q_A(x) = v^T A v$ eindeutig wenn A symmetrisch sein muss

Plücken im 2×2 Fall simpel $A = \begin{pmatrix} 2 & 3 \\ 3 & 5 \end{pmatrix}$ **ausgewählten Symmetrie nutzen** $6 = 3+3$ **Diagonalelemente korrespondieren zu quadr. Termen**

Rechnisch: $\begin{pmatrix} x & y \end{pmatrix} \begin{pmatrix} a & b \\ b & c \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} a x + b y \\ b x + c y \end{pmatrix} = x(a x + b y) + y(b x + c y) = a x^2 + 2 b x y + c y^2$ **($b x + c y$)**

b) $\theta \in \mathbb{R}^{3 \times 3}$, $Q_\theta(x) = 1 x_1^2 + 7 x_2^2 - 3 x_3^2 + 4 x_1 x_2 - 2 x_1 x_3 + 6 x_2 x_3$ $x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$ θ so bestimmen, dass $Q_\theta(x) = x^T B x$

Plücken etwas kniffliger $B = \frac{1}{2} \begin{pmatrix} 2 & 4 & -2 \\ 4 & 14 & 6 \\ -2 & 6 & -6 \end{pmatrix}$ **(2×2)**

Exkurs: Quadratische Form nicht nur isoliert interessant, sondern tauchen auch als Bestandteil anderer Konzepte auf

Skalarwertige (Vektor-)Polynome $P(\vec{x}) = x^T A x + b^T x + c$ $A \in \mathbb{R}^{n \times n}$ symmetr., $b \in \mathbb{R}^n$, $c \in \mathbb{R}$

quadr. Teil linearer Teil konstant
(quadr. Form) (Skalarprod.) (Skalar)

Skalarwertige Vektorpolynome zweifeln Erstes treten z.B. in Optimierung mit quadratischen Zielfunktionen und bei Ridge Regression auf **alternativ: Regularisierungsmethoden**

Man kann dies in höhere Dimensionen erweitern, indem man komponentenweise solche Polynome definiert

Vektorwertiges $P: \mathbb{R}^n \rightarrow \mathbb{R}^m$, $P(x) = \begin{pmatrix} x^T A_1 x + b_1^T x + c_1 \\ \vdots \\ x^T A_m x + b_m^T x + c_m \end{pmatrix}$

Quadratische Form als Funktionsinprod. Polynomen in quadratischer Form $g(x) = a \underbrace{Q_A(x)}_{\text{Skalarwertiges}} + b \underbrace{Q_B(x)}_{\text{Skalarwertiges}} + c$ **Skalarwertiges**
kann Differenzieren / Optimalen Vorgehens
 $(x^T A x)^2$ $(x^T A x)$ **Anwendung bei Funktionen, die nur vom Norm-Quadrat $\|x\|^2$ abhängen**

$\|x\|^2 = x^T I x \hat{=} \text{quadr. Form für } (x, x)$
 $\|A x\|^2 = x^T (A^T A) x$ siehe oben

• in multivariater Statistik tauchen häufig quadratische Formen auf

Bsp. Standard-NM: $f(x) = \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{1}{2} x^T \Sigma^{-1} x\right)$ Σ : Kovarianzmatrix
erst **entsprechend ist also hier**

reflexiv und transitiv

Matrix-Ordnungen $A \succ, \prec, \succeq, \preceq$ Relationen für Matrizen im Sinn der quadratischen Formen definierbar

$A \succeq B \Leftrightarrow (A-B)$ ist positiv semidefinit $A \succ B \Leftrightarrow (A-B)$ ist positiv definit

$A \geq 0 \Leftrightarrow (A-0) = A$ positiv semidefinit mit 0 gleich Nullmatrix

Bsp. Kovarianz-Vergleich $\Sigma_1 \leq \Sigma_2 \Leftrightarrow \Sigma_2$ hat mehr Streuung